

КОНКУРСНЫЙ ПРОЕКТ

SberIndex 2026

Временные ряды · 85 регионов РФ
2002–2024

Прогнозирование инвестиций в основной капитал регионов РФ и обнаружение структурных изменений

Команда: Умаров Н.Д. и Суханов А.С.

Дата: 08.10.2026

GitHub: <https://github.com/arssuhanov-coder/sberindex-2026>

■ Что решает проект

- 01 Прогнозирование инвестиций в основной капитал на 1 год вперёд для **85 регионов РФ**
- 02 Обнаружение структурных изменений (CPD) во временных рядах
- 03 Цель – превзойти Prophet на задаче прогнозирования и найти устойчивые точки слома
- 04 Период данных: **2002–2024** (23 года)

Данные проекта

Источник – БД ПМО Росстата через techno.st

Период – 2002–2024 (23 года)


Уровень – 85 субъектов РФ

Таргет – инвестиции в основной капитал, млн руб.

Признаки – оборот розничной торговли, доходы населения, безработица, ввод жилья, население (лаг 1)

Схема регионов: «без автономных округов + сами АО» – устраняет территориальное дублирование данных

■ Pipeline проекта



Пять моделей прогнозирования

Модель	Тип	Особенность
Baseline	Наивные	Лучший из Naive / MA3 / MA5 per region
ARIMA	Статистическая	Автоподбор (p, d, q)
XGBoost	ML	Панельная модель, логарифм таргета
Prophet	Статистическая	Отдельная модель на регион
Chronos	Foundation	Zero-shot, amazon/chronos-t5-small

Валидация: Train 2002–2020, Test 2021–2024

Внутри train – TimeSeriesSplit, 4 фолда

Результаты по 85 регионам (тест 2021–2024)



Модель	sMAPE mean	sMAPE median	Лидер в регионах
XGBoost	15.82%	12.70%	67
Prophet	28.44%	25.87%	9
Baseline	34.20%	34.19%	5
ARIMA	36.00%	34.19%	1
Chronos	49.51%	48.78%	3

67 / 85

регионов, где XGBoost превзошёл Prophet (79%)

42.9%

средний improvement XGBoost относительно baseline



Где XGBoost проигрывает

XGBoost хуже baseline в **11 из 85 регионов (13%)**. Причины группируются в четыре категории:

Категория	Регионы	Причина
Разворот тренда	Ингушетия, Калмыкия	Рост в train → падение в test
Сильный baseline	Архангельская (без АО)	Naïve даёт sMAPE 3.85%
Масштаб	Москва	Инвестиции в 10–20 раз выше среднего
Пограничные (7)	Коми, Вологодская, Астраханская, Ненецкий АО, Тюменская (без АО), ХМАО, Московская	Improvement в пределах шума

XGBoost улучшает baseline в 74 регионах из 85 (87%)

Обнаружение структурных изменений

CUSUM

Кумулятивные суммы отклонений от среднего; threshold = 5.0

PELT

Оптимальное разбиение; model = l2, min_size = 2, штраф = $0.7 \times \log(n)$

Binseg

Бинарная сегментация; model = l2, n_bkps = 3

Ансамбль методов

Точка консенсусная, если её нашли ≥ 2 методов из 3

Допуск ± 1 год для объединения близких точек

Снижает число ложных срабатываний

Найденные структурные сдвиги


577 детекций по 85 регионам

189 консенсусных точек (≥ 2 метода)

47 точек 3/3 консенсуса в 45 регионах

Типы: mixed — 58 · strong_jump — 14 · trend_reversal — 13

Направления: increase — 79 · decrease — 6



Основные годы сдвигов

2003–2007 — рост перед кризисом · **2015–2017** — замедление · **2020–2021** — COVID и санкции

Влияет ли CPD на качество прогноза?

После tolerance = 1 год CPD обнаруживается во всех 85 регионах – сравнение «с/без CPD» невозможно. Поэтому регионы разделены по силе сигнала CPD относительно медианы (1.4715):

Группа	Регионов	Median sMAPE
Strong CPD (сигнал > медианы)	42	11.78%
Weak CPD (сигнал ≤ медианы)	43	13.79%

Mann-Whitney U test

p = 0.2738

статистически **незначимо**

Вывод: причинная связь между силой CPD и качеством прогноза не установлена. Разница в 2 п.п. по медиане может быть случайной.

Интерпретация на примерах

Успех — Республика Хакасия

XGBoost sMAPE: **10.32%**

Improvement: **+78.7%**

CPD signal: 1.96

Годы: 2004, 2010, 2020

Тип сдвига: mixed

Провал — Республика Ингушетия

XGBoost sMAPE: **22.76%**


Baseline sMAPE: **6.36%**

Improvement: **-258%**

CPD signal: 1.50

Годы: 2004, 2011

Разворот тренда: рост → падение



Каждая модель имеет границы применимости — это нормально, главное понимать причины.

■ Что не вошло и почему

Короткие ряды — 23 наблюдения на регион ограничивают глубину ML

Внешние признаки — топ-3 признака XGBoost: лаги таргета (52% важности); внешние показатели дают менее 30%

Масштаб Москвы — инвестиции в 10–20 раз выше среднего по регионам

Горизонт — годовая частота данных; горизонты 1/3/6 месяцев недоступны

Новости — интеграция новостного потока не реализована

ML-CPD и SHAP — рассмотрены, но не реализованы в срок

■ Ключевые результаты

1. **XGBoost – лучшая модель прогнозирования.** sMAPE 15.82% против 28.44% у Prophet; превосходит Prophet в 79% регионов.
2. **CPD даёт устойчивые результаты.** 189 консенсусных точек, 47 с 3/3 консенсусом в 45 регионах.
3. **Связь CPD и прогноза не подтверждена.** Mann-Whitney $p = 0.2738$ – причинность не доказана.
4. **Методология воспроизводима.** Все скрипты запускаются из корня проекта, конфиги – в YAML.
5. **Ограничения задокументированы честно** – короткие ряды, слабый вклад внешних признаков, новости не интегрированы.

Репозиторий и документация



GitHub: <https://github.com/arssuhanov-coder/sberindex-2026>

README.md – инструкция по запуску

data_dictionary.md – словарь данных

notes/methodology.md – методологический отчёт

notes/xgboost_params.md – гиперпараметры

notebooks/final_report.ipynb – итоговый отчёт

configs/ – 7 YAML-конфигураций моделей

Контакты: email: nikita.um.04@gmail.com; Telegram команды: @tyrra